

1

1. Let  $A \in \mathbb{C}^{m \times n}$  and  $b \in \mathbb{C}^m$ . It is known that  $x_* = A^\dagger b$  is always a minimizer of the least squares problem  $\min_x \|Ax - b\|_2$  even if  $\text{rank}(A) < n$ . Show that for any other minimizer  $y$ , we have

$$\|y\|_2 \geq \|x_*\|_2.$$

解:  $A = U \Sigma_x^* V^*$  则  $A^\dagger = V \Sigma_x^{-1} U^*$

$$\Sigma_x = \begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_n & \\ & & 0 & \\ & & \vdots & \\ 0 & & & 0 \end{bmatrix}_{m \times n} \quad \Sigma_x^{-1} = \begin{bmatrix} \sigma_1^{-1} & & & 0 & \dots & 0 \\ & \ddots & & \vdots & & \\ & & \sigma_n^{-1} & & & \\ & & & 0 & \dots & 0 \end{bmatrix}_{n \times m}$$

满足  $\min_x \|Ax - b\|_2$  的  $x'$  都可表示为:

$$x' = x^* + x_0$$

其中,  $Ax_0 = 0$  (齐次方程组的解)

当  $\text{Rank}(A) < n$  时,  $x_0$  可以不等于 0

而  $x^*$  满足:  $\min_x \|Ax^* - b\|_2$

相当于一个“特解”

现在再附加一个限定, 让所有属于零空间的解也都

包含到  $x_0$  去, 则剩下的  $x^*$  就属于  $A$  的行空间

由行空间与零空间正交, 这时的  $\|x^*\|_2$  就是最小的.

下面说明  $x^*$  就是  $x_* = A^+ b$

上面已证明,  $x^*$  属于  $A$  的行空间, 下面需说明

- ①  $x_*$  满足  $\|Ax_* - b\|_2$  最小 or  $A^*Ax_* = A^*b$
- ②  $x_*$  在  $A$  的行空间中, 没有零空间的分量

$$A^*Ax_* = A^* \cdot A \cdot A^+ b \quad (A = U\Sigma V^*)$$

$$= V\Sigma^* U^* U \Sigma V^* V \Sigma^+ U^* b$$

$$= V \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{pmatrix} \cdot \begin{pmatrix} \sigma_1^{-1} & & \\ & \ddots & \\ & & \sigma_n^{-1} \end{pmatrix} \begin{pmatrix} | \\ | \\ 0 \end{pmatrix} U^* b$$

$$= V \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{pmatrix} \begin{pmatrix} | \\ | \\ 0 \end{pmatrix} U^* b \quad \text{--- (1)}$$

$$\text{而 } A^*b = (U\Sigma V^*)^* b$$

$$= V \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{pmatrix} \begin{pmatrix} | \\ | \\ 0 \end{pmatrix} U^* b \quad \text{--- (2)}$$

由 (1) = (2) 可知

$$x_* \text{ 满足法方程 } A^*Ax_* = A^*b$$

$$\text{又由 } A = \begin{pmatrix} \overline{v_1^T} \\ \vdots \\ \overline{v_m^T} \end{pmatrix} = U \cdot \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \\ \hline & & 0 \end{pmatrix} \cdot V^*$$

$$A^+ = V \Sigma_x^{-1} U^* \quad \text{其中: } \Sigma_x^{-1} = \begin{bmatrix} \sigma_1^{-1} & & & 0 & \dots & 0 \\ & \ddots & & & & \\ & & \sigma_n^{-1} & & & \\ & & & 0 & \dots & 0 \end{bmatrix}_{m \times m}$$

$$\text{则 } A^+ b = V \cdot (\Sigma_x^{-1} U^* b)$$

$X_x = A^+ b$  是  $V$  的列向量的线性组合

也就是  $V^*$  的行向量的线性组合

由  $A = U \Sigma_x V^*$  可知,  $X_x$  必落在  $A$  的行空间内

$$\text{故 } X_x = X^*$$

$$\text{则 } \forall y \in \{x'\} : \min \|Ax' - b\|_2$$

$$\text{有 } \|y\|_2 \geq \|X_x\|_2$$

2

2. Let  $A \in \mathbb{C}^{m \times n}$  and  $X \in \mathbb{C}^{n \times m}$ . Suppose that for any  $b \in \mathbb{C}^m$ ,  $x = Xb$  is always a minimizer of the least squares problem  $\min_x \|Ax - b\|_2$ . Show that  $AXA = A$  and  $(AX)^* = AX$ .

解: 由 (1) 题可知,  $X$  可分解成两部分

$$X = A^+ + T_0$$

即  $T_0$  会把  $b$  投影到零空间里, 相当于给  $X$  加上一个齐次方程的非零解  $X_0$ , 而  $X = X^* + X_0$  仍有:

$$A^* A (X^* + X_0) - A^* b = 0$$

$$\textcircled{1} AXA = A(A^+ + T_0)A$$

$$= A A^T A + A T_0 A$$

而  $T_0$  把  $\perp$  投影到零空间里,  $T_0$  与  $A$  的行空间正交, 因此  $A T_0 = 0$

又由伪逆定义:  $A^T A = I$

$$\therefore A X A = A$$

$$\textcircled{2} A (A^T + T_0)$$

$$= I + A T_0$$

$$= I + 0$$

$$= I$$

$$\therefore (A X)^* = I^* = A X$$

3

3. Generate a few least squares problems with condition numbers varying from  $10^0$  to  $10^{15}$ . Compare the accuracy of the solutions produced by the following methods:
- (a) solve the normal equation  $A^* A x = A^* b$  through the Cholesky factorization of  $A^* A$ ;
  - (b) solve the equation  $R x = Q^* b$  through the (Householder) QR factorization  $A = Q R$ .

Matlab 代码实现如下: (后有图)

```
m=10;
n=4;
b=rand(m,1);
U =orth(rand(m,m));%生成一组标准正交基 u
V =orth(rand(n,n));%生成另一组标准正交基 v
sig=zeros(m,n);
sig(2,2)=10;%
sig(3,3)=5;
sig(4,4)=1;%最小的奇异值是 1
error1=zeros(1,((7-1)/0.001+1));
error2=zeros(1,((7-1)/0.001+1));
maxsigma=zeros(1,((7-1)/0.001+1));%初始化
%%
count=1;
for k= 1:0.001:7
    sig(1,1)=10^k;%最大的奇异值从 1 增加到 10^8, 按照指数的方式增长
    A = U*sig*V';
    maxsigma(1,count)=10^k;
    %直接用 matlab 内部自带的方法计算伪逆, 并认为这个解相对精准
    x=pinv(A)*b;

    %方法一,直接解法方程 normal equation(Cholesky)
    R=chol(A'*A);
    x1=R\(R\'(A'*b));
    %[L,U]=lu(A'*A);
    %x1=U\'(L\'(A'*b));
    %x1=(A'*A)\(A'*b);
    error1(1,count)=norm(x1-x);

    %方法二, 通过 Householder 方法进行 QR 分解
    %[Q,R]=qr(A);
    A2=A;
    Q_inv=eye(m)
    for j =1:n %使用 householder 方法
        v=A2(j:m,j);
        len=norm(v);
        if v(1,1)>=0%此处相当于对 v 与一个长度为||v||且只有第一个分量不为零的向量
            v(1,1)=v(1,1)+len;%避免舍入误差
        else
            v(1,1)=v(1,1)-len;%避免舍入误差
        end
    end
end
```

```

H=eye(m-j+1)-2*(v*v')./(v'*v);
A2(j:m,j:n)=H*A2(j:m,j:n);%Householder 反射子只需要作用于 schur 补即可
H2=[eye(j-1),zeros(j-1,m-j+1);zeros(m-j+1,j-1),H];%分块矩阵，左上角为
eye，右下角为 H，其他为零
Q_inv=H2*Q_inv;
end
R=A2;
x2=R\((Q_inv*b);

%计算 x2-x1 的范数 norm
error2(1,count)=norm(x2-x);

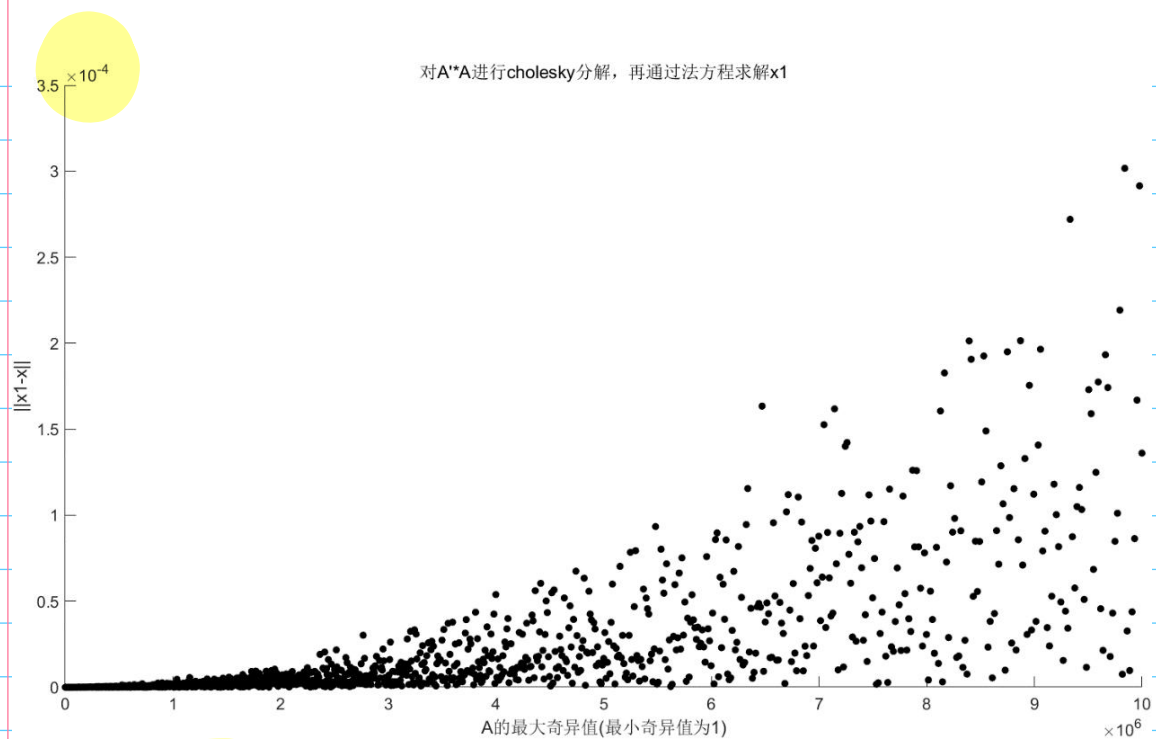
count=count+1;
end
figure(1);
scatter(maxsigma,error1,20,"black","filled");
xlabel("A 的最大奇异值(最小奇异值为 1)");
ylabel("||x1-x||");
title("对 A'*A 进行 cholesky 分解，再通过法方程求解 x1")
figure(2)
scatter(maxsigma,error2,20,"blue","filled");
xlabel("A 的最大奇异值(最小奇异值为 1)");
ylabel("||x2-x||");
title("用 Householder 方法进行 QR 分解求出 x2")

```

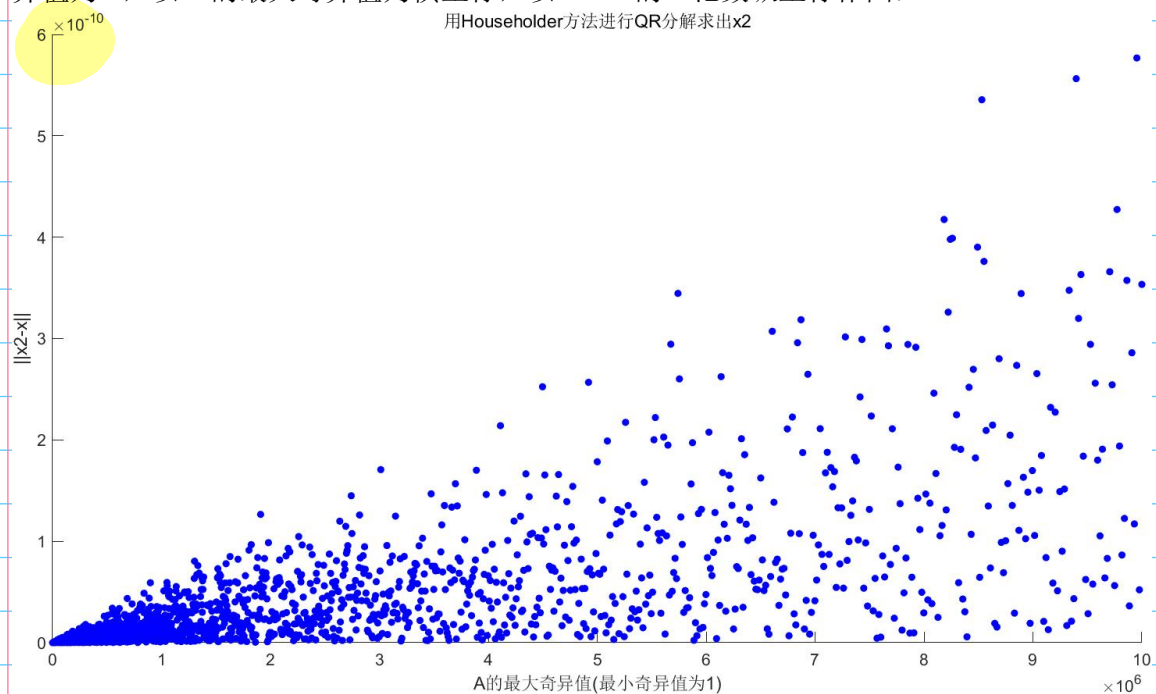
---

直接用 matlab 自带的方法计算伪逆左乘到  $b$  上，得到  $x$ ，认为这个  $x$  较为准确

通过 cholesky 分解的方法得到  $x_1$ ，计算  $x_1-x$  的二范数，并以此来衡量  $x_1$  的误差。 $A$  的最小奇异值为 1，以  $A$  的最大奇异值为横坐标，以  $x_1-x$  的二范数纵坐标作图：



通过 QR 分解的方法得到  $x_2$ , 计算  $x_2 - x$  的二范数, 并以此来衡量  $x_2$  的误差。A 的最小奇异值为 1, 以 A 的最大奇异值为横坐标, 以  $x_2 - x$  的二范数纵坐标作图:



当 A 的最大奇异值很大时, 条件数也会相应地增大。但是, QR 分解的条件数增加的速度不如用法方程求解的条件数增加的速度快。从误差的数量级也可以看出, QR 分解的精确度更高, 法方程求解的精确度较低。


4

4. Find the “best” straight line that approximately pass through the data set  $\{(n, e^{-n/2}) \in \mathbb{R}^2 : n \in \{1, 2, 3, 4, 5, 6\}\}$ . Visualize your result and clarify in what sense your solution is the best.

Matlab 代码实现如下:

```
n=1:6;
y=(exp(-n/2))';
%绘制散点图
scatter(n,y,"filled");
hold on
%用最小二乘法求斜率和截距
A=[n',ones(6,1)];
x=pinv(A)*y;
k=x(1,1);
b=x(2,1);
%绘制对应直线
Y=k*n+b;
plot(n,Y);
```

作图为:



说明: 对于  $(x_1, y_1), \dots, (x_6, y_6)$   
要找到  $k, b$  使得

$$\sum_{i=1}^6 (y_i - (kx_i + b))^2 \text{ 最小}$$



问题可以转化为解超定方程组:

$$\begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ x_3 & 1 \\ x_4 & 1 \\ x_5 & 1 \\ x_6 & 1 \end{pmatrix} \begin{bmatrix} k \\ b \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \\ y_6 \end{bmatrix}$$

记为:  $A \tilde{x} = \tilde{b}$

若  $\sum_{i=1}^6 (y_i - (k x_i + b))^2$  最小.

$\Leftrightarrow \|A \tilde{x} - \tilde{b}\|_2$  最小

则只要取:

$$\tilde{x} = \begin{pmatrix} k \\ b \end{pmatrix} = A^+ \tilde{b} \text{ 即可}$$